

**PREDIKSI DEPRESI MAHASISWA BERDASARKAN FAKTOR
AKADEMIK DAN SOSIAL DENGAN METODE DATA MINING**



**Disusun Untuk Memenuhi Tugas Besar
Mata Kuliah Penambangan Data (BBK2LAB3)**

**Oleh:
Kelompok 3**

Sridamai Wati Panjaitan	102022300049
Alya Davina Maharani	102022300220
Anisa Hanun	102022300263
Haipa Zuhaira	102022330455

**PROGRAM STUDI STRATA 1 SISTEM INFORMASI
FAKULTAS REKAYASA INDUSTRI
UNIVERSITAS TELKOM
BANDUNG
2025**

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga penulis beserta tim dapat menyelesaikan laporan Tugas Besar Mata Kuliah Penambangan Data (BBK2LAB3) dengan judul “*Prediksi Depresi Mahasiswa Berdasarkan Faktor Akademik dan Sosial dengan Metode Data Mining*” dengan baik dan tepat waktu.

Penyusunan tugas besar ini bertujuan untuk mengimplementasikan konsep dan metode data mining dalam menyelesaikan permasalahan nyata, khususnya dalam menganalisis dan memprediksi kondisi mental mahasiswa berdasarkan faktor akademik dan sosial. Melalui proses pengolahan data dan penerapan algoritma *K-Means Clustering* serta *Naïve Bayes Classifier*, diharapkan hasil analisis ini dapat memberikan wawasan yang bermanfaat dalam mendeteksi dini risiko depresi di kalangan mahasiswa.

Ucapan terima kasih kami sampaikan kepada dosen pengampu mata kuliah Penambangan Data yang telah memberikan arahan dan bimbingan selama proses pengerjaan tugas besar ini. Tak lupa kami juga mengucapkan terima kasih kepada seluruh pihak yang telah memberikan dukungan dan kontribusi, baik secara langsung maupun tidak langsung, dalam penyelesaian laporan ini.

Kami menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, kami sangat terbuka terhadap segala bentuk saran dan kritik yang membangun demi perbaikan di masa mendatang.

Akhir kata, semoga laporan tugas besar ini dapat memberikan manfaat serta menjadi tambahan pengetahuan bagi pembaca, khususnya dalam bidang data mining dan analisis prediktif.

Bandung, Mei 2025

Kelompok 4

DAFTAR ISI

Kata Pengantar.....	2
Daftar Isi.....	4
Daftar Tabel.....	5
Daftar Gambar.....	6
Ringkasan.....	7
Bab I. Pendahuluan.....	8
1.1 Latar Belakang.....	8
1.2 Rumusan Masalah.....	9
1.3 Tujuan.....	9
1.4 Manfaat.....	9
1.5 Batasan Penelitian.....	10
Bab II. Landasan Teori.....	11
2.1 Definisi Data Mining.....	11
2.2 Depresi.....	11
2.3 K-Means.....	11
2.4 Naive Bayes.....	12
2.5 State of The Art.....	12
Bab III. Metodologi Penelitian.....	14
3.1 Business Understanding.....	14
3.2 Jenis Penelitian dan Dataset yang Digunakan.....	14
3.4 Data Understanding.....	15
3.6 Data preparation.....	18
3.6.3 Train Test Split.....	18
Bab IV. Hasil dan Pembahasan.....	28
4.1 Hasil dari tahap-tahap penelitian.....	28
4.2 Pembahasan.....	28
Bab V. Penutup.....	29
5.1 Kesimpulan.....	29
5.2 Saran.....	29
Daftar Pustaka.....	30
Lampiran.....	32

Daftar Gambar

Gambar 3.1.1 Flowchart Sistematika Penyelesaian Masalah.....	13
Gambar 3.4.4.1 Statistik Data.....	23
Gambar 3.5.1.1 Missing Values.....	26
Gambar 3.5.2.1 Duplicated Data.....	26
Gambar 3.5.3.1 Outlier Before.....	27
Gambar 3.5.3.3 Outlier After.....	28
Gambar 3.6.1.1 Encoding.....	29
Gambar 3.6.1.1 Feature Scaling.....	30
Gambar 3.6.1 Train Test Split.....	30
Gambar 3.7.1.1 Modeling Naive Bayes.....	31
Gambar 3.7.2.1 Elbow Method dan Silhouette Score.....	32
Gambar 3.7.2.2 Visualisasi Elbow Method dan Silhouette Score.....	32
Gambar 3.7.3.1 K-Means Clustering.....	33
Gambar 3.7.3.2 Visualisasi Hasil Clustering.....	34
Gambar 3.7.4.1 Interpretasi Cluster.....	35
Gambar 3.8.1.1 Confusion Matrix.....	36
Gambar 3.7.2.1 Classification Report.....	37
Gambar 3.9.1 Mockup Dashboard.....	39

Ringkasan

Kesehatan mental mahasiswa telah menjadi isu yang semakin penting dalam dunia pendidikan tinggi, terutama terkait dengan gejala depresi yang dapat berdampak pada prestasi akademik dan kualitas hidup mahasiswa. Permasalahan yang diangkat dalam tugas besar ini adalah bagaimana memprediksi risiko depresi pada mahasiswa berdasarkan faktor-faktor akademik dan sosial yang tersedia dalam dataset.

Urgensi dari penelitian ini terletak pada kebutuhan institusi pendidikan untuk mendeteksi dini mahasiswa yang berpotensi mengalami depresi, sehingga dapat dilakukan intervensi preventif atau dukungan psikologis yang sesuai. Pendekatan berbasis data mining dipilih karena kemampuannya dalam mengolah data dalam jumlah besar dan menemukan pola tersembunyi yang tidak terlihat secara kasat mata.

Tujuan dari tugas besar ini adalah untuk menganalisis dan memodelkan prediksi depresi mahasiswa dengan menggunakan metode *K-Means Clustering* (unsupervised learning) untuk mengelompokkan mahasiswa berdasarkan karakteristik umum, serta *Naïve Bayes Classifier* (supervised learning) untuk memprediksi apakah seorang mahasiswa mengalami depresi atau tidak.

Metodologi yang digunakan meliputi tahapan eksplorasi data, pembersihan data (data preparation), pemodelan, evaluasi model, dan visualisasi hasil dalam bentuk dashboard interaktif. Dataset yang digunakan diperoleh dari platform Kaggle dengan judul “Student Depression Dataset” yang berisi data mahasiswa terkait tekanan akademik, durasi tidur, kebiasaan makan, stres finansial, dan variabel psikologis lainnya.

Hasil analisis menunjukkan bahwa variabel seperti academic pressure, sleep duration, financial stress, dan suicidal thoughts memiliki kontribusi signifikan dalam mempengaruhi risiko depresi pada mahasiswa. Model Naïve Bayes yang dibangun

menunjukkan performa prediksi yang cukup baik dalam mengklasifikasikan mahasiswa berdasarkan kondisi depresinya.

Dengan adanya hasil ini, diharapkan institusi pendidikan dapat mempertimbangkan pendekatan berbasis data untuk mendukung kebijakan dan program kesehatan mental mahasiswa.

Kata kunci: *Data Mining*, Depresi Mahasiswa, *Naïve Bayes*, *Clustering*, Prediksi.

Bab I. Pendahuluan

1.1 Latar Belakang

Kesehatan mental merupakan aspek penting dalam kehidupan mahasiswa yang seringkali terabaikan. Mahasiswa berada pada fase transisi menuju kedewasaan yang penuh dengan tuntutan akademik, tekanan sosial, dan tantangan finansial. Salah satu gangguan mental yang paling umum terjadi di kalangan mahasiswa adalah depresi. Gangguan ini tidak hanya berdampak pada kesejahteraan psikologis, tetapi juga mempengaruhi performa akademik, hubungan sosial, dan keputusan hidup jangka panjang.

Studi oleh Islam et al. (2020) menunjukkan bahwa tingkat depresi pada mahasiswa selama masa studi tinggi dapat mencapai lebih dari 40%, terutama pada mereka yang mengalami tekanan akademik tinggi dan minim dukungan sosial. Oleh karena itu, diperlukan sistem deteksi dini yang dapat memprediksi risiko depresi mahasiswa berdasarkan data yang tersedia.

Dengan kemajuan teknologi dan ketersediaan data, pendekatan berbasis data mining menjadi solusi yang tepat untuk mengidentifikasi pola-pola tersembunyi dalam data mahasiswa. Dengan menerapkan metode *unsupervised learning* seperti *K-Means Clustering*, dan *supervised learning* seperti *Naïve Bayes*, penelitian ini bertujuan untuk mengelompokkan dan memprediksi mahasiswa yang berisiko mengalami depresi berdasarkan karakteristik akademik dan sosial mereka.

Melalui analisis ini, diharapkan institusi pendidikan dapat memperoleh insight yang bermanfaat untuk menyusun strategi pencegahan dan penanganan depresi secara lebih sistematis dan berbasis data.

1.2 Rumusan Masalah

1. Bagaimana cara mengelompokkan mahasiswa berdasarkan karakteristik akademik dan sosial untuk mendeteksi potensi risiko depresi?
2. Bagaimana penerapan metode *K-Means Clustering* dalam proses pengelompokan mahasiswa berdasarkan data yang tersedia?
3. Bagaimana penerapan metode *Naïve Bayes* dalam memprediksi risiko depresi pada mahasiswa?
4. Sejauh mana akurasi dari model prediksi risiko depresi yang dibangun?

1.3 Tujuan

1. Mengelompokkan mahasiswa berdasarkan karakteristik akademik dan sosial untuk mengidentifikasi kelompok berisiko depresi.
2. Menerapkan metode *K-Means Clustering* dalam proses pengelompokan mahasiswa berdasarkan data akademik dan sosial.
3. Menerapkan metode *Naïve Bayes* untuk membangun model prediksi risiko depresi pada mahasiswa.
4. Mengevaluasi performa model prediksi risiko depresi berdasarkan tingkat akurasi yang dihasilkan.

1.4 Manfaat

Manfaat yang diharapkan dari penelitian ini meliputi berbagai aspek, baik dalam konteks akademis maupun praktis, antara lain:

1. Membantu mendeteksi potensi depresi pada mahasiswa berdasarkan faktor akademik dan sosial.
2. Memberikan solusi berbasis data mining untuk mendeteksi depresi secara lebih akurat.
3. Meningkatkan pemahaman tentang penerapan metode *Naive Bayes* dan *K-Means Clustering* dalam analisis kesehatan mental.

1.5 Batasan Penelitian

1. Penelitian ini hanya berfokus pada deteksi tingkat risiko depresi pada mahasiswa menggunakan data survei berupa gejala-gejala umum depresi (misalnya: pola tidur, tingkat stres, rasa cemas, dan aktivitas sosial).
2. Metode data mining yang digunakan dalam penelitian ini terbatas pada algoritma *K-Means Clustering* (untuk pengelompokan) dan *Naïve Bayes* (untuk klasifikasi).
3. Penelitian tidak membahas aspek medis atau diagnosis klinis secara langsung, melainkan sebatas pada pemetaan risiko depresi berdasarkan data yang tersedia.
4. Implementasi dilakukan menggunakan bahasa pemrograman *Python* dan *tools* pendukung seperti *Google Colab* atau *Jupyter Notebook*.

Bab II. Landasan Teori

2.1 Definisi *Data Mining*

Data mining merupakan salah satu metode dalam ilmu komputer yang digunakan untuk menggali informasi pada sejumlah data. Proses ini melibatkan beberapa tahapan untuk menemukan pola-pola tertentu dalam database. Umumnya, *data mining* banyak diterapkan dalam bidang statistik dan *machine learning*. (Prastiwi et al., 2022).

2.2 Depresi

Depresi adalah salah satu gangguan kesehatan mental yang dapat dialami oleh semua orang tanpa memandang usia. Bahkan angka depresi di dunia sudah mencapai 300 juta orang atau sekitar 3,76% populasi dunia. Menurut WHO, penyebab kematian paling berdampak pada 15 tahun kedepan adalah depresi. (Abimayu, Bahtiar, & Sarwoko, 2023).

Oleh karena itu, dibutuhkan deteksi dini untuk menanggulangi depresi. Salah satu metode yang dapat digunakan untuk deteksi dini adalah pemanfaatan *data mining*, yang memungkinkan analisis pola dan prediksi kondisi psikologis berdasarkan variabel yang ada, seperti tekanan di lingkungan sekitar, stres keuangan, atau bahkan kebiasaan makan. *Data mining* dapat mengidentifikasi tanda-tanda awal depresi dengan menganalisis data dalam jumlah besar yang sebelumnya sulit untuk dianalisis secara manual.

2.3 *K-Means*

Salah satu metode data mining yang relevan untuk mendeteksi pola depresi pada pelajar adalah algoritma *K-Means Clustering*. Salah satu metode data mining yang relevan untuk mendeteksi pola depresi pada pelajar adalah algoritma *K-Means Clustering*. *K-Means Clustering* bekerja dengan cara mengelompokkan data berdasarkan jarak paling dekat dari masing-masing data ke titik pusat (*centroid*)

cluster. (Firdaus et al., 2021). Metode ini memungkinkan identifikasi kelompok risiko depresi secara lebih terstruktur, sehingga dapat mendukung pengambilan keputusan dalam upaya pencegahan dan penanganan yang lebih tepat sasaran.

2.4 *Naive Bayes*

Berdasarkan penelitian yang dilakukan oleh Mokoagow dan Purnomo (2023) *naive bayes* merupakan algoritma klasifikasi berbasis probabilitas yang bekerja dengan menghitung peluang dari kombinasi nilai pada suatu data. Metode ini dikenal cukup akurat dalam melakukan diagnosis karena memanfaatkan kemungkinan kemunculan gejala-gejala tertentu untuk memperkirakan kondisi atau penyakit yang mungkin dialami. Dalam konteks deteksi depresi, *Naive Bayes* dapat digunakan untuk memprediksi tingkat risiko berdasarkan data survei atau parameter psikologis yang dimiliki individu.

2.5 *State of The Art*

Penelitian dalam bidang prediksi depresi menggunakan teknik data mining terus berkembang, seiring dengan meningkatnya perhatian terhadap kesehatan mental, khususnya di kalangan mahasiswa. Berbagai pendekatan telah dilakukan untuk menganalisis faktor-faktor penyebab depresi, baik dari sisi akademik maupun sosial, dengan tujuan mendeteksi gejala depresi secara lebih dini dan akurat.

Salah satu penelitian relevan dilakukan oleh Nur Rakhmad Setiawan (2023) dalam penelitiannya yang berjudul “*Perbandingan Klasifikasi Gejala Depresi Menggunakan Naive Bayes, Decision Tree, dan K-Nearest Neighbor*”. Penelitian tersebut menilai efektivitas berbagai algoritma klasifikasi dalam mengenali gejala depresi berdasarkan data kuesioner. Hasilnya menunjukkan bahwa algoritma *Naive Bayes* memberikan akurasi yang baik dan mampu mengenali pola-pola depresi secara sederhana namun efisien. Hal ini menunjukkan potensi NBC dalam pengklasifikasian kondisi mental berdasarkan data akademik dan sosial yang bersifat kategorikal dan numerik.


Sementara itu, Kurniawan et al. (2023) dalam penelitian berjudul “*Analisis Kesehatan Mental Mahasiswa Menggunakan K-Means Clustering*” memanfaatkan metode K-Means untuk mengelompokkan mahasiswa berdasarkan tingkat kesehatan mental. Algoritma ini efektif dalam menemukan pola tersembunyi dan kelompok yang memiliki karakteristik serupa dari data kuesioner. Meskipun demikian, metode *clustering* ini tidak secara langsung memberikan klasifikasi status depresi individu, namun berguna untuk mengidentifikasi kelompok risiko tinggi yang memerlukan perhatian lebih lanjut.

Dari dua penelitian tersebut, terlihat bahwa *Naive Bayes* unggul dalam klasifikasi berbasis data input yang eksplisit, sedangkan *K-Means* mampu mengelompokkan data untuk menemukan pola tersembunyi yang tidak diketahui sebelumnya. Namun, masih jarang penelitian yang menggabungkan kedua pendekatan ini secara bersamaan untuk memberikan hasil prediksi yang lebih akurat dan bervariasi, terutama yang mengkaji faktor akademik dan sosial secara bersamaan.

Berdasarkan celah tersebut, tugas besar ini bertujuan untuk mengembangkan sistem prediksi depresi mahasiswa dengan menggabungkan metode *Naive Bayes Classifier* dan *K-Means Clustering*, guna mengklasifikasikan tingkat depresi sekaligus mengelompokkan mahasiswa berdasarkan karakteristik akademik dan sosial mereka. Kombinasi ini diharapkan mampu memberikan pendekatan yang lebih menyeluruh dalam deteksi dini depresi serta mendukung pengambilan keputusan intervensi yang tepat.

Bab III. Metodologi Penelitian

3.1 *Flowchart Sistematika Penyelesaian Masalah*



Gambar 3.1.1 *Flowchart Sistematika Penyelesaian Masalah*

3.2 *Business Understanding*

Analisis dataset untuk prediksi depresi pada mahasiswa menjadi sangat penting dalam memahami dan mengatasi tantangan kesehatan mental di lingkungan pendidikan. Dengan menggunakan metode data mining seperti *K-Means Clustering* dan *Naïve Bayes*, proyek ini bertujuan memberikan wawasan berbasis data untuk mendukung pengambilan keputusan yang lebih efektif dalam penanganan kesehatan mental mahasiswa. Berbagai pihak, seperti universitas, layanan konseling kampus, dan pemerintah, dapat memanfaatkan hasil prediksi ini untuk tujuan strategis, seperti:

1. **Deteksi Dini Depresi:** Membantu dosen, pembimbing akademik, dan psikolog kampus mengidentifikasi mahasiswa yang berisiko tinggi mengalami depresi,

sehingga intervensi seperti konseling atau program pendampingan dapat dilakukan lebih cepat.

2. Perencanaan Program Kesehatan Mental: Memungkinkan universitas atau lembaga pendidikan merancang kebijakan dan *workshop* (misalnya: manajemen stres, *peer counseling*) yang lebih terarah berdasarkan kelompok risiko mahasiswa.
3. Optimalisasi Layanan Konseling: Dengan mengetahui distribusi mahasiswa berisiko, unit konseling kampus dapat mengalokasikan sumber daya (misalnya: jumlah konselor, jadwal sesi) secara lebih efisien. Peningkatan Kualitas Akademik: Depresi seringkali berdampak pada penurunan IPK, *drop out*, atau keterlambatan studi.
4. Prediksi ini membantu fakultas memberikan dukungan akademik khusus (misalnya: *academic advising*) kepada mahasiswa yang rentan. Evaluasi Kebijakan Kampus: Pihak universitas dapat menilai efektivitas kebijakan terkait kesehatan mental (contoh: *flexible deadline*, cuti akademik) dengan memantau tren risiko depresi sebelum dan setelah implementasi.

3.2.1 Model Klasifikasi (*Naïve Bayes*)

Model klasifikasi ini dirancang untuk memprediksi apakah seorang mahasiswa berisiko mengalami depresi atau tidak dengan dua kelompok utama:

- Tidak Berisiko = 0

Mahasiswa dengan indikator kesehatan mental yang stabil, seperti:

- Tekanan akademik & pekerjaan rendah
- Kepuasan studi & kerja baik
- Pola tidur normal (≥ 7 jam/hari)
- Tidak ada riwayat pikiran bunuh diri
- Stres finansial terkendali

- Berisiko = 1

Mahasiswa yang menunjukkan gejala depresi, seperti:

- Tekanan akademik/pekerjaan tinggi
- Kepuasan studi & kerja rendah
- Gangguan tidur (<5 jam/hari)
- Pernah ada pikiran bunuh diri
- Stres finansial berat
- Riwayat keluarga dengan gangguan mental

Tujuan utama model prediksi depresi mahasiswa ini adalah membantu perguruan tinggi mengidentifikasi mahasiswa berisiko secara dini, sehingga unit konseling dapat memberikan intervensi tepat sasaran berupa konseling intensif, penyesuaian akademik, atau program pencegahan, sekaligus memungkinkan kampus mengalokasikan sumber daya kesehatan mental secara lebih efektif berdasarkan data prediksi.

3.2.2 Model Clustering (K-Means)

Model *clustering* digunakan untuk mengelompokkan individu berdasarkan kemiripan pola data. Dalam konteks dataset ini, algoritma ***K-Means*** dimanfaatkan untuk membagi data ke dalam beberapa klaster yang mencerminkan tingkat risiko kesehatan mental, berdasarkan variabel-variabel seperti:

- Usia
- Tekanan akademik
- IPK (Indeks Prestasi Kumulatif)
- Kepuasan belajar
- Durasi belajar/bekerja

Sebelum proses *clustering* dilakukan, dapat diterapkan teknik PCA (*Principal Component Analysis*) untuk mereduksi dimensi data.

Pendekatan ini membantu menyederhanakan struktur data, sehingga proses klasterisasi menjadi lebih efisien dan akurat.

Hasil dari proses *clustering* ini menghasilkan lima kelompok mahasiswa dengan karakteristik sebagai berikut:

- **Kelompok Sangat Rentan (*Cluster 0.0*):**
Mahasiswa dengan gejala depresi berat, tekanan akademik tinggi, gangguan tidur parah, dan kemungkinan adanya pikiran suicidal.
- **Kelompok Cukup Stabil (*Cluster 1.0*):**
Masih menunjukkan beberapa gejala depresi (seperti stres akademik atau kecemasan), tetapi masih mampu mengelola aktivitas sehari-hari.
- **Kelompok Stabil Skala Kecil (*Cluster 2.0*):**
Kesehatan mental relatif baik dengan gejala minimal, namun tetap rentan jika menghadapi tekanan tambahan.
- **Kelompok Rentan (*Cluster 3.0*):**
Gejala depresi sedang (misalnya gangguan tidur atau penurunan motivasi) dengan faktor risiko seperti isolasi sosial atau stres finansial.
- **Kelompok Butuh Perhatian Khusus (*Cluster 4.0*):**
Menunjukkan kombinasi faktor kompleks seperti riwayat keluarga, tekanan eksternal tinggi, dan gejala psikologis serius.

3.2.3 Fokus Analisis

Depresi pada mahasiswa merupakan salah satu gangguan kesehatan mental yang paling umum dan prevalensinya terus meningkat di lingkungan akademik. Dengan memanfaatkan teknik data mining, penelitian ini berfokus pada dua pendekatan utama, yaitu *Naïve Bayes* untuk klasifikasi dan *K-Means Clustering* untuk pengelompokan data

mahasiswa. Model *Naïve Bayes* dirancang untuk memprediksi risiko depresi berdasarkan parameter seperti IPK, tingkat stres akademik, durasi tidur, riwayat pikiran suicidal, dan tekanan finansial. Hasil klasifikasi ini memberikan kategori risiko (berisiko atau tidak berisiko) untuk membantu unit konseling kampus dalam memprioritaskan mahasiswa yang membutuhkan pendampingan. Sementara metode *K-Means Clustering* digunakan untuk mengelompokkan mahasiswa berdasarkan karakteristik psikologis dan akademik yang serupa, sehingga memungkinkan identifikasi kelompok rentan yang memerlukan intervensi khusus, seperti mahasiswa dengan gejala depresi berat yang butuh penanganan intensif.

3.2.4 Manfaat bagi Organisasi/*Stakeholders*

Proyek ini memberikan manfaat yang signifikan bagi berbagai pemangku kepentingan di lingkungan pendidikan. Bagi konselor kampus dan tenaga kesehatan mental, model ini memungkinkan identifikasi mahasiswa yang membutuhkan perhatian khusus berdasarkan tingkat risiko depresi mereka. Melalui hasil clustering, institusi pendidikan dapat merancang program intervensi yang tepat sasaran, seperti konseling kelompok atau workshop manajemen stres yang disesuaikan dengan karakteristik setiap kluster. Bagi pihak administrasi kampus dan pembuat kebijakan, hasil analisis ini dapat menjadi dasar untuk mengembangkan kebijakan pencegahan yang lebih efektif, seperti program peer support atau penyesuaian sistem akademik yang lebih memperhatikan kesehatan mental mahasiswa. Selain itu, data ini dapat digunakan untuk mengoptimalkan alokasi sumber daya konseling dan layanan kesehatan mental di kampus. Dalam perspektif jangka panjang, pendekatan berbasis data ini tidak hanya meningkatkan efektivitas layanan kesehatan mental di lingkungan kampus, tetapi juga dapat mengurangi dampak negatif depresi yang tidak tertangani, seperti penurunan prestasi akademik, kasus

dropout, atau masalah kesehatan mental yang lebih serius di kemudian hari. Dengan demikian, proyek ini berkontribusi pada penciptaan lingkungan akademik yang lebih sehat dan mendukung kesuksesan mahasiswa secara holistik.

3.2.5 Keberhasilan Model

Evaluasi performa model klasifikasi dalam proyek ini dilakukan menggunakan confusion matrix sebagai metrik utama. Confusion matrix digunakan untuk membandingkan hasil prediksi model terhadap data aktual dan terdiri dari empat komponen utama:

1. True Positive (TP):

Mahasiswa berisiko depresi yang terprediksi benar.

2. True Negative (TN):

Mahasiswa tidak berisiko yang terprediksi benar.

3. False Positive (FP):

Mahasiswa tidak berisiko tetapi salah diprediksi sebagai berisiko (*over-prediction*).

4. False Negative (FN):

Mahasiswa berisiko yang terlewat dan tidak terdeteksi (*under-prediction*).

3.2.6 Tindak Lanjut dan Implementasi

Hasil analisis ini akan diimplementasikan sebagai rekomendasi konkret bagi unit konseling kampus dan pemangku kebijakan pendidikan. Model klasifikasi digunakan untuk memprioritaskan mahasiswa berisiko tinggi agar segera mendapat pendampingan psikologis serta mengoptimalkan alokasi sumber daya konseling berdasarkan tingkat urgensi. Sementara itu, hasil clustering dimanfaatkan untuk menyusun program intervensi spesifik seperti workshop manajemen stres atau pelatihan peer support, serta mendorong kebijakan akademik yang lebih

fleksibel bagi mahasiswa dengan gejala depresi. Untuk menjaga keakuratan prediksi, evaluasi berkala akan dilakukan dengan mempertimbangkan dinamika data dan kondisi mahasiswa, serta diarahkan pada pengembangan model yang lebih canggih dan integrasi dengan sistem informasi kampus.

3.2.7 Jenis Penelitian dan Dataset yang Digunakan

Penelitian ini menggunakan jenis penelitian eksperimen, dimana dilakukan pengujian terhadap beberapa algoritma machine learning untuk memprediksi tingkat depresi pada mahasiswa berdasarkan data yang telah dikumpulkan. Eksperimen ini bertujuan untuk mengetahui algoritma dengan performa terbaik melalui evaluasi metrik seperti akurasi, *precision*, *recall*, dan *F1-score*. Dari segi sifatnya, penelitian ini bersifat deskriptif karena menyajikan hasil pengujian secara sistematis dalam bentuk grafik dan tabel. Pendekatan yang digunakan adalah kuantitatif, karena data yang diolah bersifat numerik dan hasil analisisnya bersifat objektif. Sebagai bentuk implementasi dari hasil penelitian, dikembangkan aplikasi prediksi berbasis web menggunakan Streamlit untuk mempermudah interaksi pengguna dengan model prediksi yang dibangun.

3.3 Data Collection

3.3.1 Sumber Dataset

Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle, yang berjudul *Students' Mental Health Dataset*. Dataset ini berisi informasi komprehensif mengenai kesehatan mental mahasiswa, termasuk data demografis, tekanan akademik dan pekerjaan, kebiasaan hidup, serta indikator kesehatan mental lainnya. Tujuan utama dari dataset ini adalah untuk menganalisis faktor-faktor yang mempengaruhi depresi pada mahasiswa. Dataset ini dapat diakses melalui tautan: [<https://www.kaggle.com/datasets/adilshamim8/student-depression-dataset>] .

3.3.2 Tujuan penggunaan

Dataset ini digunakan untuk:

1. **Menganalisis Faktor Risiko Depresi**

Mengidentifikasi pola hubungan antara variabel seperti tekanan akademik, kebiasaan tidur, stres finansial, dan riwayat kesehatan mental dengan gejala depresi pada mahasiswa.

2. **Membangun Model Prediktif**

Mengembangkan algoritma klasifikasi (Naïve Bayes) untuk memprediksi risiko depresi berdasarkan karakteristik akademik, sosial, dan psikologis mahasiswa.

3. **Segmentasi Mahasiswa**

Menerapkan clustering (K-Means) guna mengelompokkan mahasiswa berdasarkan tingkat kerentanan depresi, sehingga intervensi dapat disesuaikan dengan kebutuhan tiap kelompok.

4. **Dukungan Kebijakan Kampus**

Memberikan dasar empiris untuk perancangan program pencegahan depresi yang terarah, seperti konseling, workshop kesehatan mental, atau penyesuaian kebijakan akademik.

5. **Validasi Ilmiah**

Memastikan temuan penelitian berbasis data nyata yang dapat direplikasi atau dikembangkan lebih lanjut.

3.4 *Data Understanding*

3.4.1 Pemahaman Data

Dataset ini berisi informasi terkait parameter akademik, psikologis, dan gaya hidup mahasiswa yang dapat memengaruhi risiko depresi. Setiap baris pada dataset mewakili seorang mahasiswa dengan sejumlah atribut yang menggambarkan:

- Profil Demografis (jenis kelamin, usia)

- Kondisi Akademik (IPK, beban studi, kepuasan belajar)
- Kebiasaan Hidup (pola tidur, pola makan)
- Indikator Kesehatan Mental (stres finansial, riwayat pikiran bunuh diri, riwayat keluarga)

3.4.2 Karakteristik Data

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27901 entries, 0 to 27900
Data columns (total 13 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Gender                                     27901 non-null  object
1   Age                                       27901 non-null  float64
2   Academic Pressure                       27901 non-null  float64
3   CGPA                                    27901 non-null  float64
4   Study Satisfaction                     27901 non-null  float64
5   Sleep Duration                         27901 non-null  object
6   Dietary Habits                         27901 non-null  object
7   Degree                                 27901 non-null  object
8   Have you ever had suicidal thoughts ?  27901 non-null  object
9   Work/Study Hours                      27901 non-null  float64
10  Financial Stress                       27901 non-null  object
11  Family History of Mental Illness       27901 non-null  object
12  Depression                             27901 non-null  int64
dtypes: float64(5), int64(1), object(7)
memory usage: 2.8+ MB
```

Gambar 3.3.2.1 Karakteristik Data

Dataset ini terdiri dari 27.901 entri dan 13 kolom tanpa nilai yang hilang. Sebagian besar kolom bertipe data object, sementara lima kolom bertipe *float64* dan satu kolom bertipe *int64*, yaitu kolom target *Depression*. Data mencakup informasi akademik, psikologis, serta kebiasaan hidup mahasiswa, seperti tekanan akademik, kepuasan belajar, durasi tidur, dan stres finansial. Dataset ini memerlukan pra-pemrosesan lebih lanjut untuk mengubah data bertipe *object* menjadi format numerik sebelum dianalisis lebih lanjut.

3.4.3 Deskripsi Data

Dataset ini berisi 10 sampel data mahasiswa dengan 13 atribut yang mencakup faktor akademik, psikologis, dan gaya hidup. Berikut analisis deskriptifnya:

1. Variabel Kategorikal

- **Gender:** Terdiri dari Male dan Female.
- **Dietary Habits:** Healthy, Moderate, dan Unhealthy.
- **Degree:** Beragam jenjang pendidikan (Contoh: B.Pharm, BSc, PhD, LLB).
- **Suicidal Thoughts:** Yes dan No.
- **Family History of Mental Illness:** Yes dan No.
- **Depression:** 1 (Depresi) dan 0 (Tidak depresi).

2. Variabel Numerik

- **Age:** Rentang usia 24–33 tahun (rata-rata ~28.5 tahun).
- **Academic Pressure:** Skala 1–5 (5 = tekanan tertinggi).
- **CGPA**
- **Study Satisfaction:** Skala 1–5 (1 = tidak puas, 5 = sangat puas).
- **Work/Study Hours:** Variasi 0–12 jam/hari.
- **Financial Stress:** Skala 1–5 (5 = stres tertinggi).

3. Variabel Khusus

- **Sleep Duration:**
 1. Less than 5 hours → Mayoritas terkait dengan depresi.
 2. 5–6 hours.
 3. 7–8 hours.

3.4.4 Statistik Data

```
df.describe()
```

	Age	Academic Pressure	CGPA	Study Satisfaction	Work/Study Hours	Depression
count	27901.000000	27901.000000	27901.000000	27901.000000	27901.000000	27901.000000
mean	25.822300	3.141214	7.656104	2.943837	7.156984	0.585499
std	4.905687	1.381465	1.470707	1.361148	3.707642	0.492645
min	18.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25%	21.000000	2.000000	6.290000	2.000000	4.000000	0.000000
50%	25.000000	3.000000	7.770000	3.000000	8.000000	1.000000
75%	30.000000	4.000000	8.920000	4.000000	10.000000	1.000000
max	59.000000	5.000000	10.000000	5.000000	12.000000	1.000000

Gambar 3.4.4.1 Statistik Data

1. Jumlah Data (count)

- Semua variabel memiliki **27901** entri yang berarti data ini memiliki 27.901 sampel untuk masing-masing kolom.

2. Rata-Rata (mean)

- **Age (Usia)**: Rata-rata usia individu dalam data ini adalah **25.82 tahun**.
- **Academic Pressure (Tekanan Akademik)**: Rata-rata tekanan akademik yang dialami adalah **3.14**.
- **CGPA**: Rata-rata IPK atau CGPA adalah **7.66**.
- **Study Satisfaction (Kepuasan Studi)**: Rata-rata kepuasan studi adalah **2.94**.
- **Work/Study Hours (Jam Kerja/Studi)**: Rata-rata jam kerja atau studi adalah **7.16 jam** per hari.
- **Depression (Depresi)**: Rata-rata individu yang mengalami depresi adalah **0.59**, yang menunjukkan bahwa sekitar 59% dari data menunjukkan kondisi depresi.

3. Standar Deviasi (std)

- **Age:** Standar deviasi usia adalah **4.91 tahun**, yang menunjukkan variasi yang cukup besar dalam usia individu.
- **Academic Pressure:** Variabilitas tekanan akademik adalah **1.38**, menunjukkan tingkat tekanan akademik yang beragam.
- **CGPA:** Standar deviasi CGPA adalah **1.47**, yang menunjukkan variasi dalam nilai akademik peserta.
- **Study Satisfaction:** Standar deviasi kepuasan studi adalah **1.36**, yang menunjukkan bahwa sebagian besar individu merasa kurang puas dengan studi mereka, dengan variasi yang signifikan.
- **Work/Study Hours:** Variasi dalam jam kerja atau studi adalah **3.71 jam**, menunjukkan perbedaan yang cukup besar dalam jumlah jam yang dihabiskan oleh individu untuk bekerja atau belajar.
- **Depression:** Standar deviasi pada kolom depresi adalah **0.49**, menunjukkan distribusi yang hampir merata antara individu yang mengalami depresi dan yang tidak.

4. Nilai Minimum dan Maksimum

- **Age:** Rentang usia berkisar antara **18 hingga 59 tahun**.
- **Academic Pressure:** Nilai tekanan akademik berkisar antara **0 hingga 5**, dengan 0 menunjukkan tidak ada tekanan akademik dan 5 menunjukkan tekanan maksimal.
- **CGPA:** CGPA berkisar antara **0 hingga 10**, dengan nilai terendah adalah 0 dan tertinggi adalah 10.
- **Study Satisfaction:** Nilai kepuasan studi berkisar antara **0 hingga 5**, dengan 0 menunjukkan kepuasan sangat rendah dan 5 menunjukkan kepuasan maksimal.
- **Work/Study Hours:** Jam kerja atau studi berkisar antara **0 hingga 12 jam**.

- **Depression:** Kolom ini memiliki nilai 0 dan 1, di mana 0 berarti individu tidak mengalami depresi, dan 1 berarti individu mengalami depresi.

5. Persentil

- **25%:** Nilai persentil ke-25 menunjukkan bahwa 25% individu memiliki nilai lebih rendah dari angka yang tertera.
- **50% (Median):** Nilai persentil ke-50 menunjukkan nilai tengah, dengan setengah data berada di bawah dan setengah di atas nilai ini.
- **75%:** Nilai persentil ke-75 menunjukkan bahwa 75% individu memiliki nilai lebih rendah dari angka ini.

3.4.5 Keterbatasan Data

Beberapa kolom seperti Degree (B.Pharm, BSc, LLB, dll) dan Sleep Duration, 'Gender', 'Sleep Duration', 'Dietary Habits', 'Degree', 'Have you ever had suicidal thoughts ?', serta 'Family History of Mental Illness' (dalam format string) memerlukan preprocessing lebih lanjut (contoh: one-hot encoding) sebelum pemodelan.

3.5 Data Exploration

3.5.1 Missing Values

```
print(df.isnull().sum())
```

Gender	0
Academic Pressure	0
CGPA	0
Study Satisfaction	0
Sleep Duration	0
Dietary Habits	0
Degree	0
Have you ever had suicidal thoughts ?	0
Work/Study Hours	0
Financial Stress	0
Family History of Mental Illness	0
Depression	0
dtype: int64	

Gambar 3.5.1.1 Missing Values

Berdasarkan hasil pemeriksaan nilai kosong menggunakan fungsi `df.isnull().sum()` dari library *pandas*, diketahui bahwa seluruh kolom pada dataset tidak mengandung nilai kosong (missing values). Hal ini menunjukkan bahwa data sudah lengkap dan tidak memerlukan proses imputasi atau penghapusan baris/kolom akibat kekosongan data.

3.5.2 Duplicated Data


```
[198] total_duplicates = df.duplicated().sum()
      print(f"Jumlah data duplikat: {total_duplicates}")
```

➡ Jumlah data duplikat: 0

Gambar 3.5.2.1 Duplicated Data

Data yang digunakan diperiksa dari kemungkinan duplikasi menggunakan fungsi `df.duplicated()`. Ditemukan sebanyak 0 data duplikat.

3.5.3 Handle Outlier



Gambar 3.5.3.1 *Outlier Before*

```
df_clean = df.copy()

df_numerik = df_clean.select_dtypes(include='number')

jumlah_sebelum = df_clean.shape[0]

# Hitung IQR
Q1 = df_numerik.quantile(0.25)
Q3 = df_numerik.quantile(0.75)
IQR = Q3 - Q1

# Deteksi baris dengan outlier
outlier_condition = (df_numerik < (Q1 - 1.5 * IQR)) | (df_numerik > (Q3 + 1.5 * IQR))


# Hapus baris outlier dari df_clean
df_clean = df_clean[~outlier_condition.any(axis=1)]

jumlah_setelah = df_clean.shape[0]

print(f"Jumlah data sebelum: {jumlah_sebelum}")
print(f"Jumlah data setelah: {jumlah_setelah}")
```

Jumlah data sebelum: 27901
Jumlah data setelah: 27880

3.5.3.2 Handling Outlier



Gambar 3.5.3.3 Outlier After

Berdasarkan boxplot awal, ditemukan beberapa outlier pada data numerik seperti CGPA dan Work/Study Hours. Outlier dibersihkan menggunakan metode IQR. Setelah pembersihan, jumlah data hanya berkurang sedikit (27901 → 27880), menunjukkan bahwa outlier tidak terlalu banyak. Proses ini tetap penting untuk menjaga kualitas data dan hasil analisis yang lebih akurat.

3.6 Data Preprocessing

3.6.1 Encoding

```
import pandas as pd
import numpy as np

df = df.replace('?', np.nan)
categorical_cols = [
    'Gender', 'Sleep Duration', 'Dietary Habits', 'Degree',
    'Have you ever had suicidal thoughts?', 'Family History of Mental Illness'
]

df_encoded = pd.get_dummies(df, columns=categorical_cols)
df_encoded = df_encoded.apply(pd.to_numeric, errors='coerce')

# df = df.drop('CGPA_Binned', axis=1)

df_encoded.head()
```

Gambar 3.6.1.1 Encoding

Setelah dilakukan proses encoding terhadap data kategorikal, dataset telah berhasil diubah sepenuhnya menjadi bentuk numerik dengan total 34 kolom. Fitur-fitur seperti Gender, Degree, Have you ever had suicidal thoughts?, dan Family History of Mental Illness yang sebelumnya bertipe kategorikal, kini telah dikonversi menjadi kolom biner (True/False) menggunakan metode one-hot encoding. Selain itu, fitur-fitur numerik asli seperti Age, Academic Pressure, CGPA, dan Depression tetap dipertahankan. Hasil ini memastikan seluruh variabel dapat digunakan dalam algoritma pembelajaran mesin seperti K-Means, yang mensyaratkan input numerik.

3.6.2 Feature Scaling

```
features_for_clustering = [
    'Age', 'Academic Pressure', 'CGPA', 'Study Satisfaction', 'Work/Study Hours',
    'Financial Stress', 'Gender_Female', 'Gender_Male',
    "Sleep Duration_'5-6 hours'", "Sleep Duration_'7-8 hours'",
    "Sleep Duration_'Less than 5 hours'", "Sleep Duration_'More than 8 hours'", "Sleep Duration_Others",
    'Dietary Habits_Healthy', 'Dietary Habits_Moderate',
    'Dietary Habits_Others', 'Dietary Habits_Unhealthy',
    'Degree_Class 12', 'Degree_B.Arch', 'Degree_B.Com', 'Degree_B.Ed',
    'Degree_B.Tech', 'Degree_BCA', 'Degree_BHM', 'Degree_M.Tech',
    'Degree_MCA', 'Degree_MSc', 'Degree_Others',
    'Have you ever had suicidal thoughts ?_No',
    'Have you ever had suicidal thoughts ?_Yes',
    'Family History of Mental Illness_No',
    'Family History of Mental Illness_Yes'
]

X = df_scaled[features_for_clustering]

X.head()
```

Gambar 3.6.1.1 *Feature Scaling*

Pada tahap ini, ditentukan fitur-fitur yang akan digunakan untuk proses clustering dan disimpan dalam variabel `features_for_clustering`. Fitur tersebut mencakup data numerik seperti Age, CGPA, Depression, serta hasil encoding dari variabel kategorikal seperti Gender, Sleep Duration, Dietary Habits, Degree, Have you ever had suicidal thoughts?, dan Family History of Mental Illness. Pemilihan fitur dilakukan secara selektif agar mencerminkan karakteristik psikologis dan akademik responden secara menyeluruh. Kemudian, data yang telah diskalakan (`df_scaled`) difilter berdasarkan fitur-fitur tersebut dan disimpan dalam variabel `X`, yang akan digunakan sebagai input untuk algoritma clustering.

3.6.3 Train Test Split

```
[157] from sklearn.model_selection import train_test_split

y = df_encoded[['Depression']]
X = df_encoded.drop(columns=['Depression'])

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

Gambar 3.6.1 *Train Test Split*

Train-test split digunakan dalam penelitian ini untuk memastikan bahwa model prediksi yang dibangun dapat menggeneralisasi dengan baik terhadap data

yang tidak terlihat sebelumnya. Proses ini membagi dataset menjadi dua bagian: satu untuk melatih model (training set) dan satu lagi untuk mengujinya (test set). Dalam konteks tugas besar ini, tujuan utama dari train-test split adalah untuk mencegah model mengalami overfitting terhadap data pelatihan dan untuk mengukur akurasi serta kinerja model pada data yang belum pernah dilihat sebelumnya. Dengan membagi data secara acak, kita dapat memastikan bahwa model memiliki kemampuan generalisasi yang baik, yang sangat penting dalam deteksi dini risiko depresi pada mahasiswa menggunakan dataset yang memuat berbagai faktor akademik dan sosial.

3.7 Modeling

3.7.1 Naive Bayes

```
[58] from sklearn.naive_bayes import GaussianNB

model = GaussianNB()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
```

Gambar 3.7.1.1 *Modeling Naive Bayes*

Pada tahap ini, digunakan model Gaussian Naïve Bayes untuk memprediksi risiko depresi mahasiswa berdasarkan data yang telah diproses. Algoritma ini bekerja dengan mengasumsikan bahwa setiap fitur bersifat independen dan menghitung probabilitas kelas menggunakan Teorema Bayes. Kode yang digunakan melibatkan pembuatan model dengan `GaussianNB()`, melatih model menggunakan dataset pelatihan (`fit(X_train, y_train)`), dan kemudian memprediksi kelas pada data uji dengan `predict(X_test)`. Hasil prediksi ini menentukan apakah seorang mahasiswa berisiko depresi atau tidak berdasarkan fitur-fitur yang ada dalam data.


3.7.2 *Elbow Method* dan *Sillhoutte Score*

```
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

# --- Elbow dan Silhouette ---
inertia = []
silhouette_scores = []
k_values = list(range(2, 11))

for k in k_values:
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    kmeans.fit(X_scaled)
    inertia.append(kmeans.inertia_)
    silhouette = silhouette_score(X_scaled, kmeans.labels_)
    silhouette_scores.append(silhouette)
```

Gambar 3.7.2.1 *Elbow Method* dan *Sillhoutte Score*



Gambar 3.7.2.2 Visualisasi *Elbow Method* dan *Sillhoutte Score*

Penentuan jumlah kluster optimal dilakukan menggunakan dua pendekatan utama, yaitu Elbow Method dan Silhouette Score. Berdasarkan visualisasi Elbow Method, penurunan nilai inertia menunjukkan pola menurun tajam dari $k = 2$ hingga $k = 5$, lalu cenderung melandai setelahnya. Hal ini menunjukkan bahwa peningkatan jumlah kluster setelah $k = 5$ tidak lagi memberikan pengurangan inertia yang signifikan. Sementara itu, analisis menggunakan Silhouette Score menunjukkan nilai tertinggi terjadi pada $k = 2$, namun secara praktis jumlah kluster sebanyak dua dianggap terlalu sederhana

untuk mencerminkan keragaman data. Silhouette Score cukup stabil dan relatif tinggi pada $k = 5$ hingga $k = 7$.

Dengan mempertimbangkan titik siku pada grafik inertia serta stabilitas skor Silhouette, maka diputuskan untuk menggunakan $k = 5$ sebagai jumlah kluster akhir. Nilai ini dipilih karena mampu menangkap kompleksitas pola dalam data dengan baik tanpa menghasilkan kluster yang terlalu sedikit maupun terlalu banyak.

3.7.3 *K-Means Clustering*

```
pca = PCA()
X_pca_full = pca.fit_transform(X_scaled)
cumulative_variance = np.cumsum(pca.explained_variance_ratio_)
n_components_60 = np.argmax(cumulative_variance >= 0.6) + 1

pca_final = PCA(n_components=n_components_60)
X_pca = pca_final.fit_transform(X_scaled)

# Clustering K-Means
kmeans = KMeans(n_clusters=5, random_state=42, n_init=10)
labels = kmeans.fit_predict(X_pca)
```


Gambar 3.7.3.1 *K-Means Clustering*

Pada tahapan ini, dilakukan reduksi dimensi menggunakan metode Principal Component Analysis (PCA) untuk menyederhanakan data yang memiliki banyak fitur (dimensi), sekaligus mempertahankan informasi penting yang terkandung di dalamnya. Prosesnya dimulai dengan mentransformasikan data `X_scaled` ke bentuk PCA penuh (`X_pca_full`), lalu dihitung cumulative variance untuk mengetahui seberapa banyak variansi data yang dapat dijelaskan oleh sejumlah komponen utama (principal components).

Berdasarkan hasil kumulatif variansi tersebut, dipilih jumlah komponen (`n_components_60`) yang mampu menjelaskan setidaknya 60% variansi total, sebagai ambang batas informasi yang ingin dipertahankan. Data

kemudian ditransformasikan ulang (X_{pca}) menggunakan jumlah komponen yang sudah ditentukan.

Setelah proses reduksi dimensi, dilakukan proses klusterisasi menggunakan algoritma K-Means dengan jumlah klaster ditentukan sebanyak 5. K-Means bertujuan untuk mengelompokkan data hasil PCA ke dalam klaster-klaster berdasarkan kemiripan fitur yang telah direduksi tersebut. Hasil klusterisasi disimpan dalam variabel labels.



Gambar 3.7.3.2 Visualisasi Hasil *Clustering*

Principal Component Analysis (PCA) digunakan untuk mereduksi dimensi dataset dari fitur yang banyak menjadi dua komponen utama (PCA1 dan PCA2), yang memudahkan visualisasi. K-Means clustering kemudian diterapkan untuk membagi data menjadi tiga klaster berdasarkan kedekatannya dengan centroid. Hasil clustering ini ditandai dengan label pada setiap titik data.

Hasil visualisasi menunjukkan scatter plot dari dua komponen utama (PCA1 vs. PCA2) dengan data yang dikelompokkan ke dalam tiga klaster yang

terpisah dengan jelas. Masing-masing klaster diberi warna yang berbeda (hijau, oranye, dan biru), yang menunjukkan pemisahan data yang berhasil oleh K-Means clustering setelah pengurangan dimensi menggunakan PCA.

Ini menunjukkan bahwa dengan menggunakan PCA untuk reduksi dimensi dan K-Means untuk clustering, data terbagi dengan jelas ke dalam tiga klaster yang terpisah.

3.7.4 Interpretasi *Cluster*

Cluster	Cluster_Label	Age	Academic Pressure	CGPA	Study Satisfaction	Work/Study Hours	Depression	Jumlah Anggota	
0	0.0	Kelompok Sangat Rentan	25.814123	3.179347	7.674043	2.943660	7.287168	0.625209	6585
1	1.0	Kelompok Cukup Stabil	25.972796	3.078026	7.621244	2.944116	7.038380	0.528469	4742
2	2.0	Kelompok Stabil (Skala Kecil)	25.887208	3.049860	7.658674	2.981513	7.087395	0.519701	5355
3	3.0	Kelompok Rentan	25.771114	3.182611	7.666653	2.936501	7.234281	0.618801	4819
4	4.0	Kelompok Butuh Perhatian Khusus	25.703611	3.193685	7.653419	2.918087	7.110521	0.616852	6397

Persentase Suicidal Thoughts per Cluster (%):

Have you ever had suicidal thoughts ?		
Cluster	No	Yes
0.0	30.706150	69.293850
1.0	47.595951	52.404049
2.0	46.928105	53.071895
3.0	30.960780	69.039220
4.0	30.639362	69.360638

Gambar 3.7.4.1 Interpretasi *Cluster*

Hasil clustering K-Means dengan k=5 menghasilkan lima kelompok mahasiswa dengan karakteristik berbeda. Setiap cluster diberi label deskriptif berdasarkan nilai rata-rata dari fitur-fitur utama.


- Cluster 0 – Kelompok Sangat Rentan
Depresi tinggi (0.625), 69.3% memiliki pikiran bunuh diri, dan jam belajar tertinggi.
- Cluster 1 – Kelompok Cukup Stabil
Depresi terendah (0.528), suicidal thoughts 52.4%, relatif paling stabil.
- Cluster 2 – Kelompok Stabil (Skala Kecil)
Mirip cluster 1, dengan suicidal thoughts 53.1%, kelompok kecil.

- Cluster 3 – Kelompok Rentan
Depresi tinggi (0.619), suicidal thoughts 69.0%, tekanan akademik tertinggi.
- Cluster 4 – Kelompok Butuh Perhatian Khusus
Suicidal thoughts tertinggi (69.4%), depresi 0.617.

Kelompok 0, 3, dan 4 memiliki tingkat risiko psikologis tertinggi dan perlu menjadi prioritas perhatian.

3.8 Evaluation

3.8.1 *Confusion Matrix*



Gambar 3.8.1.1 *Confussion Matrix*

Berdasarkan gambar tersebut, diperoleh beberapa informasi penting mengenai performa model:

- *True Positive* (2733 kasus): Individu yang mengalami depresi berhasil dikenali dengan benar oleh model.

- *True Negative* (1779 kasus): Individu yang tidak mengalami depresi juga berhasil diprediksi dengan tepat.
- *False Positive* (569 kasus): Model memprediksi individu mengalami depresi, padahal sebenarnya tidak.
- *False Negative* (499 kasus): Model memprediksi individu tidak mengalami depresi, padahal sebenarnya mengalami depresi.

Hasil ini menunjukkan bahwa model memiliki kemampuan yang baik dalam mengenali kasus depresi (ditunjukkan oleh jumlah True Positive yang tinggi). Namun demikian, masih terdapat sejumlah kesalahan klasifikasi, terutama pada False Positive dan False Negative, yang dapat berpengaruh terhadap keandalan model dalam skenario nyata. Oleh karena itu, perbaikan model atau eksplorasi metode lain dapat dipertimbangkan untuk meningkatkan performa secara keseluruhan.

3.8.2 *Classification Report*

```

Accuracy: 0.8086021505376344
Classification Report:

```

	precision	recall	f1-score	support
0	0.78	0.76	0.77	2348
1	0.83	0.85	0.84	3232
accuracy			0.81	5580
macro avg	0.80	0.80	0.80	5580
weighted avg	0.81	0.81	0.81	5580

Gambar 3.7.2.1 *Classification Report*

Berdasarkan hasil evaluasi menggunakan metrik klasifikasi, model Naive Bayes menunjukkan performa yang cukup baik dalam mendeteksi depresi. Berikut adalah ringkasan metrik performa yang diperoleh:

- Akurasi model sebesar 0.88 atau 88%, yang menunjukkan bahwa secara keseluruhan, model mampu mengklasifikasikan data dengan benar sebanyak 88% dari total 5.580 data uji.

- Performa per kelas:

1. Kelas 0 (Tidak Depresi):

- Precision: 0.78 → Dari seluruh prediksi "tidak depresi", 78% benar.
- Recall: 0.76 → Dari seluruh data aktual "tidak depresi", 76% berhasil dikenali oleh model.
- F1-Score: 0.77 → Menunjukkan keseimbangan yang baik antara precision dan recall untuk kasus tidak depresi.

2. Kelas 1 (Depresi):

- Precision: 0.83 → Dari seluruh prediksi "depresi", 83% benar.
- Recall: 0.85 → Dari seluruh data aktual "depresi", 85% berhasil dikenali oleh model.
- F1-Score: 0.84 → Menunjukkan keseimbangan yang baik antara precision dan recall untuk kasus depresi.

Selain itu, rata-rata performa model juga ditampilkan dalam bentuk macro average dan weighted average, yang masing-masing memiliki precision, recall, dan F1-score sebesar 80% dan 81%. Secara umum, model lebih baik dalam mengenali kasus depresi (kelas 1) dibandingkan tidak depresi (kelas 0), seperti yang terlihat dari nilai recall dan F1-score yang lebih tinggi pada kelas 1.

3.9 Mockup Dashboard

Prediksi Depresi Pada Mahasiswa

Masukkan data mahasiswa untuk memprediksi kemungkinan mengalami depresi.

Evaluasi Model

Accuracy: 0.78

Accuracy: 0.78

Accuracy: 0.78

Pilih grafik untuk ditampilkan:

Confusion Matrix

Confusion Matrix

Prediksi Risiko Depresi

Silahkan isi data ini dengan jujur. Data ini tidak akan disimpan.

Jenis Kelamin

Female

Jenjang Pendidikan

B.Tech

Tingkat Tekanan Akademik

0.005.0010

Tingkat Kepuasan Studi

0.005.0010

Durasi Tidur Rata-rata

'7-8 hours'

Kebiasaan Makan

Moderate

Total Jam Belajar/Bekerja per Hari

0-+

Tingkat Stres Keuangan

0.003.005.00

Pernah Memiliki Pikiran Bunuh Diri?

No

Riwayat Keluarga dengan Gangguan Mental

No

Prediksi

Hasil Prediksi

Pasien diprediksi: **Tidak Depresi**

Probabilitas depresi: 0.01

Gambar 3.9.1 Mockup Dashboard

Bab IV. Hasil dan Pembahasan

4.1 Hasil dari tahap-tahap penelitian

4.1.1 Data Exploration

Dataset yang ada, terdapat beberapa fitur numerik dan kategorikal. Di antaranya: Age, Academic Pressure, CGPA, Study Satisfaction, Work/Study Hours, Financial Stress, Depression, Gender, Sleep Duration, Dietary Habits, Degree, Suicidal Thoughts, serta Family History of Mental Illness. Hasil dari eksplorasi, didapatkan informasi sebagai berikut:

- Distribusi usia mahasiswa berkisar antara awal 20-an hingga 40-an, dengan mayoritas berada di rentang 20–30 tahun.
- Sebagian besar mahasiswa memiliki tekanan akademik dan stres finansial di tingkat sedang hingga tinggi.
- Tingkat kepuasan belajar bervariasi, namun cenderung lebih rendah pada mahasiswa dengan skor depresi tinggi.
- Terdapat persentase signifikan mahasiswa yang mengaku memiliki pikiran bunuh diri.
- Fitur kategorikal seperti Degree memiliki distribusi yang luas, dengan 10 kategori dominan yang kemudian difokuskan dalam tahap selanjutnya.

1. Missing Value

Setelah dilakukan proses pembersihan dan penanganan data kosong, hasil pemeriksaan menggunakan fungsi `df.isnull().sum()` menunjukkan bahwa seluruh kolom dalam dataset tidak lagi mengandung nilai kosong (NaN). Hal ini berarti setiap fitur seperti Gender, Age, Academic Pressure, CGPA, hingga Depression telah lengkap dan siap digunakan dalam proses pemodelan lebih lanjut.

2. Duplicate

Setelah dilakukan pengecekan data duplikat menggunakan fungsi `df.duplicated().sum()`, diperoleh hasil bahwa jumlah data duplikat adalah

0. Artinya, tidak ada baris data yang identik satu sama lain secara keseluruhan.

3. *Handling Outlier*

Jumlah data sebelum pembersihan adalah 27.901 baris, dan setelah preprocessing menjadi 27.880 baris. Sebanyak 21 baris dihapus karena tidak lengkap atau tidak valid.

4.1.2 Data Preprocessing

Tahap preprocessing dimulai dengan encoding fitur kategorikal menggunakan One-Hot Encoding, agar fitur seperti Gender, Sleep Duration, Degree, dan lainnya dapat diubah menjadi format numerik. Selanjutnya, dilakukan scaling terhadap seluruh fitur numerik menggunakan Min-Max Scaling agar setiap fitur berada dalam rentang 0 hingga 1, sehingga algoritma machine learning dapat memprosesnya dengan optimal.

Setelah semua fitur berada dalam bentuk numerik dan berskala seragam, dilakukan pemilihan fitur (feature selection) untuk memastikan hanya variabel relevan yang digunakan dalam model. Tahap akhir preprocessing adalah pembagian data menjadi data latih dan data uji (train-test split) dengan proporsi tertentu, agar model dapat dilatih dan diuji secara adil.

4.1.3 Clustering (K-Means)

Sebelum melakukan proses klasterisasi, data yang telah dinormalisasi (X_{scaled}) terlebih dahulu direduksi dimensinya menggunakan teknik Principal Component Analysis (PCA). Tujuan dari reduksi dimensi ini adalah untuk menyederhanakan struktur data yang kompleks menjadi representasi yang lebih ringkas, sekaligus tetap mempertahankan informasi penting.

Berdasarkan hasil cumulative variance, dipilih sejumlah komponen utama yang mampu menjelaskan setidaknya 60% variansi total, yang kemudian digunakan untuk membentuk data baru (X_{pca}). Transformasi ini menghasilkan

dua komponen utama pertama (PC1 dan PC2) yang digunakan untuk proses visualisasi dan analisis clustering.

Hasil klasterisasi menggunakan algoritma K-Means menghasilkan lima kelompok mahasiswa yang masing-masing memiliki karakteristik berbeda berdasarkan variabel seperti usia, tekanan akademik, jam belajar, tingkat depresi, dan pikiran bunuh diri. Berikut adalah interpretasi dari masing-masing cluster:

Cluster 0 – Kelompok Sangat Rentan

- Tingkat depresi tertinggi (0.625).
- Suicidal thoughts sangat tinggi: 69.3% mahasiswa di klaster ini mengaku pernah memiliki pikiran bunuh diri.
- Jam belajar paling tinggi di antara semua klaster, yaitu 7.28 jam per hari.
- Tekanan akademik juga cukup tinggi (rata-rata 3.17).
- Kelompok ini berisi mahasiswa dengan kondisi mental paling rentan, kemungkinan besar karena beban akademik tinggi yang tidak sebanding dengan coping mechanism yang dimiliki.

Cluster 1 – Kelompok Cukup Stabil

- Tingkat depresi terendah di antara semua klaster (0.528).
- Persentase suicidal thoughts terendah kedua: 52.4%.
- Jam belajar relatif sedang, dan tekanan akademik juga sedikit lebih rendah dari klaster rentan.
- Ini merupakan kelompok dengan kondisi psikologis yang relatif stabil, meskipun angka suicidal thoughts masih cukup tinggi dan tetap perlu perhatian preventif.

Cluster 2 – Kelompok Stabil (Skala Kecil)

- Mirip dengan Cluster 1, namun ukuran klaster lebih kecil.
- Depresi terendah kedua (0.519).
- Suicidal thoughts di angka 53.1%, sedikit lebih tinggi dari Cluster 1.
- Menunjukkan bahwa meskipun tergolong stabil, tetap ada potensi risiko psikologis yang tidak boleh diabaikan.

Cluster 3 – Kelompok Rentan

- Depresi tinggi (0.619), mendekati Cluster 0.
- Suicidal thoughts sangat tinggi: 69.0%.
- Tekanan akademik tertinggi di antara semua klaster (3.18).
- Ini adalah kelompok mahasiswa yang mengalami tekanan psikologis signifikan, baik dari sisi akademik maupun mental, meskipun sedikit lebih rendah dibanding Cluster 0 dari sisi jam belajar.

Cluster 4 – Kelompok Butuh Perhatian Khusus

- Persentase suicidal thoughts tertinggi dari semua klaster: 69.4%.
- Tingkat depresi juga sangat tinggi (0.616).
- Tekanan akademik paling tinggi kedua, dengan kepuasan belajar paling rendah.

4.1.4 Naive Bayes

Pada tahap klasifikasi, algoritma Naive Bayes digunakan untuk memprediksi apakah seseorang mengalami depresi atau tidak berdasarkan variabel-variabel prediktor yang tersedia. Evaluasi performa dilakukan melalui confusion matrix dan classification report.

Berdasarkan hasil confusion matrix, diperoleh performa klasifikasi sebagai berikut:

1. **True Positive (TP):** 2.733 kasus → individu yang benar-benar mengalami depresi berhasil dikenali oleh model.


2. **True Negative (TN):** 1.779 kasus → individu yang tidak mengalami depresi berhasil diprediksi dengan tepat.
3. **False Positive (FP):** 569 kasus → individu yang sebenarnya tidak mengalami depresi namun diprediksi depresi oleh model.
4. **False Negative (FN):** 499 kasus → individu yang sebenarnya mengalami depresi namun tidak terdeteksi oleh model.

Evaluasi lebih lanjut dilakukan menggunakan metrik klasifikasi, dengan hasil sebagai berikut:

- **Akurasi model:** 0.88 (88%)
- **Kelas 0 – Tidak Depresi:**
 - Precision: 0.78
 - Recall: 0.76
 - F1-Score: 0.77
- **Kelas 1 – Depresi:**
 - Precision: 0.83
 - Recall: 0.85
 - F1-Score: 0.84

Model menunjukkan kinerja lebih baik dalam mendeteksi kasus depresi (kelas 1) dibandingkan tidak depresi (kelas 0), terutama ditunjukkan oleh nilai recall dan F1-score yang lebih tinggi pada kelas 1. Rata-rata performa model juga cukup baik, dengan macro average F1-score sebesar 80% dan weighted average sebesar 81%.

4.2 Dashboard



Gambar 4.2.2 Dashboard

Bab V. Penutup

5.1 Kesimpulan

Penelitian ini berhasil menunjukkan bahwa pendekatan data mining dapat dimanfaatkan secara efektif untuk memprediksi risiko depresi pada mahasiswa berdasarkan faktor akademik dan sosial. Dengan menggunakan algoritma K-Means Clustering dan Naïve Bayes Classifier, model yang dikembangkan mampu mengelompokkan mahasiswa ke dalam lima kluster dengan karakteristik kesehatan mental yang berbeda-beda, serta memprediksi secara cukup akurat apakah seorang mahasiswa berisiko mengalami depresi.

Hasil klasifikasi menunjukkan bahwa variabel seperti tekanan akademik, durasi tidur, stres finansial, dan pikiran bunuh diri memiliki pengaruh signifikan terhadap tingkat risiko depresi. Model Naïve Bayes yang dibangun menunjukkan performa yang memuaskan dengan akurasi sebesar 88%, dan lebih efektif dalam mengenali kasus depresi dibandingkan yang tidak depresi. Temuan ini memperkuat urgensi penerapan pendekatan berbasis data dalam mendeteksi dini potensi masalah kesehatan mental di lingkungan pendidikan tinggi, yang dapat menjadi dasar dalam pengambilan keputusan oleh pihak institusi untuk intervensi dan perencanaan program kesehatan mental mahasiswa secara lebih terarah.

5.2 Saran

Berdasarkan hasil penelitian, disarankan agar pengumpulan data dilakukan secara lokal di institusi pendidikan masing-masing guna menghasilkan model prediksi yang lebih relevan dengan kondisi nyata. Selain itu, model prediksi yang telah dibangun dapat diintegrasikan ke dalam sistem informasi kampus untuk mendukung layanan konseling dan pemantauan kesehatan mental mahasiswa secara real-time. Untuk meningkatkan keandalan model, eksplorasi lebih lanjut terhadap algoritma lain seperti Random Forest atau SVM juga perlu dilakukan sebagai perbandingan performa.

Dalam implementasinya, penting untuk memastikan bahwa seluruh proses tetap memperhatikan aspek etis dan menjaga privasi data mahasiswa dengan baik. Selanjutnya, penerapan sistem prediksi ini sebaiknya dilakukan melalui kolaborasi antara pihak akademik, konseling, dan teknologi informasi agar dapat memberikan dampak yang optimal. Program pendampingan dan intervensi juga perlu disesuaikan dengan karakteristik tiap klaster yang ditemukan, sehingga pendekatan yang dilakukan benar-benar tepat sasaran dan efektif dalam meningkatkan kesejahteraan mental mahasiswa.

Daftar Pustaka

Depression and anxiety among university students during the COVID-19 pandemic in Bangladesh: A web-based cross-sectional survey.
<https://www.sciencedirect.com/science/article/pii/S1877050921006840?via%3Dihub>

Prastiwi, H., Pricilia, J., & Rasywir, E. (2022). Implementasi Data Mining Untuk Menentuksn Persediaan Stok Barang Di Mini Market Menggunakan Metode K-Means Clustering. *Jurnal Informatika Dan Rekayasa Komputer (JAKAKOM)*, 2(1), 141-148. <https://ejournal.unama.ac.id/index.php/jakakom/article/view/34>

Abimanyu, S., Bahtiar, N., & Sarwoko, E. A. (2023). Implementasi Metode Support Vector Machine (SVM) Dan T-Distributed Stochastic Neighbor Embedding (T-Sne) Untuk Klasifikasi Depresi. *Jurnal Masyarakat Informatika*, 14(2), 146-158. <https://ejournal.undip.ac.id/index.php/jmasif/article/view/59513/24999>

Firdaus, H. S., Nugraha, A. L., Sasmito, B., & Awaluddin, M. (2021). Perbandingan metode fuzzy c-means dan k-means untuk pemetaan daerah rawan kriminalitas di kota semarang. *Elipsoida: Jurnal Geodesi dan Geomatika*, 4(01), 58-64. <https://ejournal2.undip.ac.id/index.php/elipsoida/article/view/9219/6693>

Mokoagow, M. A., & Purnomo, A. S. (2024). Penerapan Metode Naïve Bayes Pada Sistem Pakar Untuk Mendiagnosis Penyakit Ibu Hamil. *JEKIN-Jurnal Teknik Informatika*, 4(2), 309-323. <https://www.rumahjurnal.or.id/index.php/JEKIN/article/view/803>

Ahmad Khan, A. (2022). Balanced split: A new train-test data splitting strategy for imbalanced datasets.

Lampiran

Link Dataset: [student_depression_dataset.csv](#)

Link Google Colab:  DATMIN_KELOMPOK 3.ipynb

Video Presentasi:  Video Presentasi Penambangan Data - Kelompok 3.mp4